Trabalho ATP – Gestão de Big Data

Oct 23, 2026 · @André

André Marques

1. Dados e objetivo

O ficheiro atpplayers.json tem 1 308 835 documentos. Cada documento é um jogo de singulares visto do lado de um jogador: jogador, local de nascimento, altura, mão, torneio, local, datas, piso, prémio, ronda, ranking do adversário, adversário, resultado (W/L) e marcador.

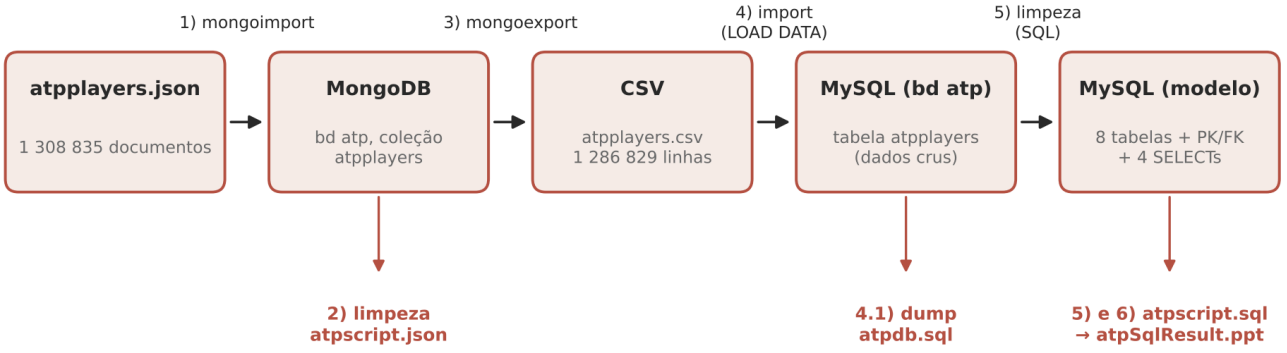
Os dados cobrem 9 960 jogadores (identificados pelo código ATP) e 22 235 edições de torneios, quase todas entre 1973 e 2022. Incluem ATP Tour, Grand Slams, Challengers, Futures, Taça Davis e rondas de qualificação.

O objetivo é construir em MySQL uma base de dados relacional, flexível e fácil de entender, com todas as restrições de integridade, e responder a quatro perguntas:

1. Por país: número de jogadores, de torneios e de rondas.
2. Top 10 jogadores por % de vitórias.
3. Top 10 esquerdinos por % de vitórias em jogos de Grand Slam.
4. Top 5 jogadores com mais vitórias em piso duro (Hard).

2. Processo

Os dados passam por seis passos. A limpeza está dividida entre o MongoDB (estrutura e registos inválidos) e o MySQL (normalização e regras de negócio).



Ficheiro	Passo	Conteúdo
atpscript.json	2	Script mongosh de limpeza da coleção atpplayers
atpdb.sql	4.1	Dump da bd atp com a tabela atpplayers, tal como veio do CSV (sem transformações SQL)
atpscript.sql	5 e 6	Começa com `use atp`; cria o modelo relacional, limpa os dados e corre as 4 consultas
atpSqlResult.ppt	6	Uma tabela por consulta

3. Limpeza no MongoDB (atpscript.json)

O script corre sobre a coleção atpplayers importada com mongoimport. Remove 22 006 documentos (1,7%) e deixa 1 286 829 para exportar.

Passo	O que faz	Porquê	Documentos removidos
1	Renomeia GameRound → Round, GameRank → OpponentRank, Oponent → Opponent	Nomes com erros ou pouco claros (é também o formato da versão MySQL do Moodle)	0
2	Cria PlayerId a partir do LinkPlayer (ex.: d643) e apaga o LinkPlayer	Há 7 nomes partilhados por jogadores diferentes (ex.: Martin Damm), por isso o nome não serve de chave	0
3	Trim dos textos; Born vazio, Hand = "null", Ground e Prize vazios → null; Height e OpponentRank não numéricos ("NA", "-") → null; Score passa a texto; "&" → "&"	Uniformizar tipos e valores em falta	0
4	Apaga byes (Opponent = "bye") e registos sem resultado W/L	Um bye é uma passagem direta, não um jogo	19 260
5	Apaga duplicados exatos (todos os campos iguais exceto _id), fica o primeiro	O mesmo jogo aparecia repetido	2 746

No fim, o mongoexport gera o CSV com 15 colunas: PlayerId, PlayerName, Born, Height, Hand, Tournament, Location, Date, Ground, Prize, Round, OpponentRank, Opponent, WL, Score.

4. Import para MySQL e dump (atpdb.sql)

O CSV entra no MySQL sem transformações: uma tabela atpplayers na bd atp, com todas as colunas VARCHAR(100), igual à versão MySQL disponibilizada no Moodle mais a coluna PlayerId. Foram importadas as 1 286 829 linhas, sem perdas.

O import usa `LOAD DATA INFILE` a partir da pasta /var/lib/mysql-files do servidor (Docker). O dump foi feito com `mysqldump --databases atp`, por isso o atpdb.sql cria a bd atp (se não existir) e começa com `USE atp`. Corre com `mysql -u -p < atpdb.sql` numa bd atp vazia.

O dump usa também `--set-gtid-purged=OFF`. Num servidor com GTIDs ativos (o MySQL 9 do Docker tem-nos ligados), o dump inclui por defeito `SET @@GLOBAL.GTID_PURGED`. Ao importar numa bd já usada, isso dá o erro 3546 e a importação para.

5. Modelo relacional

O modelo tem 8 tabelas. No centro está a tabela game, com um jogo por linha visto do lado de um jogador, ligada ao jogador, à edição do torneio e à ronda. As tabelas atpplayers (dados crus) e cleaning_log (contagens da limpeza) ficam na bd, mas não fazem parte do modelo.

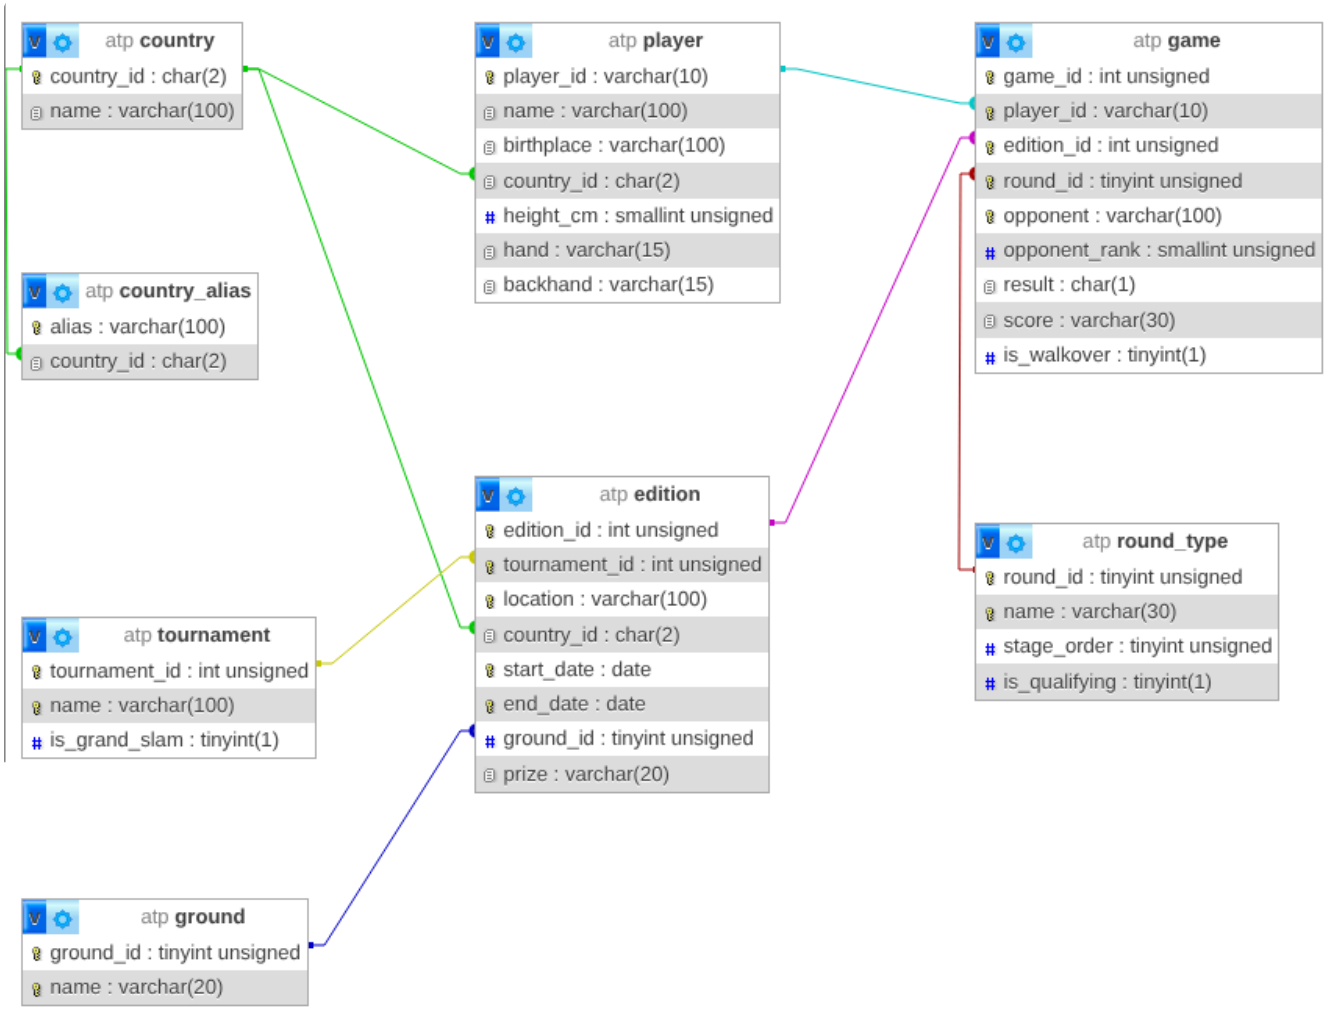


Tabela	Linhas	Chave primária	Chaves estrangeiras	Outras restrições
country	249	country_id (ISO 3166-1, 2 letras)	–	name NOT NULL
country_alias	1 187	alias	country_id → country	–
player	9 960	player_id (código ATP)	country_id → country	altura entre 150 e 220 cm; hand e backhand com valores fixos (CHECK)
tournament	5 332	tournament_id	–	name UNIQUE; is_grand_slam 0/1

Tabela	Linhas	Chave primária	Chaves estrangeiras	Outras restrições
edition	22 235	edition_id	tournament_id → tournament; country_id → country; ground_id → ground	UNIQUE (torneio, local, datas); end_date ≥ start_date
ground	4	ground_id	–	name UNIQUE
round_type	13	round_id	–	name UNIQUE; stage_order; is_qualifying 0/1
game	1 286 812	game_id	player_id → player; edition_id → edition; round_id → round_type	UNIQUE (jogador, edição, ronda, adversário); result IN ('W','L')

Decisões de modelação:

- **Torneio e edição separados.** "Wimbledon" é um torneio; "Wimbledon 2019" é uma edição, com local, datas, piso e prémio próprios. Assim, a marcação de Grand Slam fica num só sítio.
- **Piso e prémio na edição.** Dependem da edição e não do jogo, por isso não se repetem em 1,3 milhões de linhas.
- **Adversário como texto.** Muitos adversários não estão na lista de jogadores e há nomes repetidos, por isso uma ligação pelo nome seria ambígua.
- **Índices para as consultas:** game (player_id, result, is_walkover), game (edition_id), player (hand), player (country_id), edition (ground_id), edition (country_id) e tournament (is_grand_slam).

6. Limpeza e transformação em SQL (atpscript.sql)

O script começa com `use atp`, apaga as tabelas que cria (pode correr mais do que uma vez) e preenche o modelo a partir da tabela atpplayers. Corre em cerca de 2 minutos num MySQL 8.0 em modo estrito.

Campo	Problema encontrado	Tratamento
Born	6 276 jogadores sem local de nascimento; formatos variados ("Belgrade, Serbia", "Miami, FL", "Moscow", "U.S.A.")	País pela última parte do texto e, se falhar, pela primeira, através da tabela country_alias; 17 cidades ambíguas (ex.: "San Juan", "Salem") ficam sem país
Location	Mesmo problema nos locais dos torneios; locais "TBA"	Mesmo mapeamento; 41 edições ficam sem país
Height	Valores impossíveis (0, 3, 15, 71, 244, 510)	Fora de 150–220 cm → NULL
Hand	"Right-Handed, Two-Handed Backhand" junta duas informações	Dividido em hand e backhand; "Unknown Backhand" → NULL
Date	"2021.11.22 - 2021.12.05" ou só "1984.05.07"	start_date e end_date (DATE); com uma só data, início = fim
Date	3 edições com fim antes do início (ex.: New Haven 1992.08.10 - 1992.08.09)	end_date → NULL
Ground / Prize	1 edição com dois pisos; 120 com o prémio escrito de duas formas ("$" e "€")	Fica o valor máximo (MAX)
Score	5 484 vitórias por falta de comparência, "(W/O)"	Marcadas em is_walkover
Jogo	17 duplicados lógicos (mesmo jogador, edição, ronda e adversário)	Agrupados numa só linha

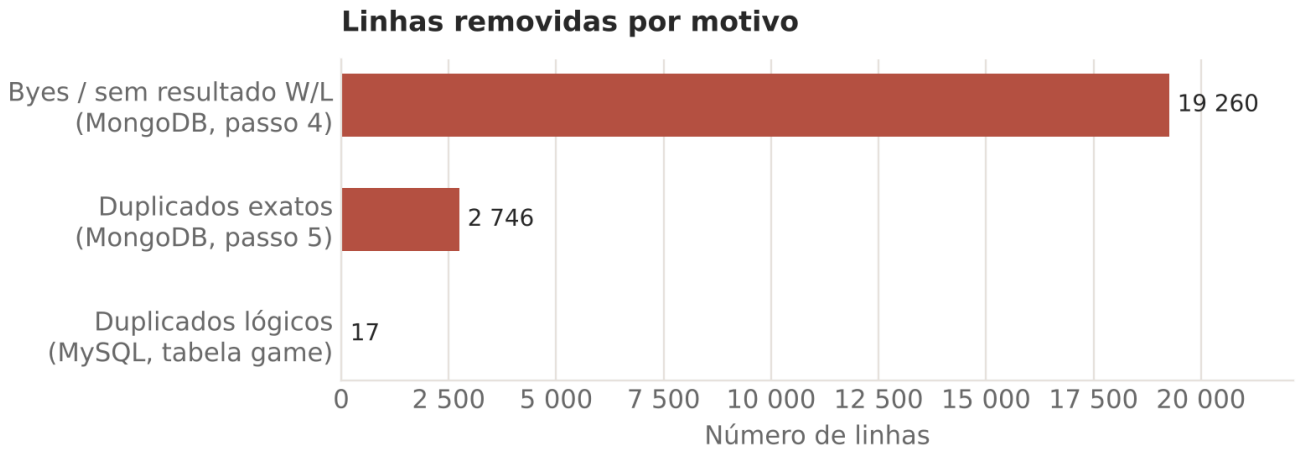
Países sem o countries_net.csv. Em vez de carregar o ficheiro com `LOAD DATA LOCAL INFILE`, o script inclui a lista ISO 3166-1 (a mesma do link do enunciado, datahub country-list) em INSERTs. O `LOAD DATA LOCAL` exige `local_infile` ativo no cliente e no servidor, e no MySQL 8 vem desligado por defeito. Assim, o script não depende de nenhum ficheiro externo. A tabela country_alias junta 1 187 variantes encontradas nos dados: nomes alternativos (USA, England, Czech Rep.), estados dos EUA (CA, NY), países históricos (Czechoslovakia → República Checa, Yugoslavia → Sérvia) e cidades que aparecem sem país. As cidades foram mapeadas com a base de dados mundial de cidades GeoNames, só quando o nome não é ambíguo (o país mais populoso com esse nome tem pelo menos 3 vezes a população do segundo). Cerca de 100 nomes com erros ou encoding estragado (ex.: "Hyvink€€", "Mar del Palta") foram mapeados à mão.

Todas as contagens ficam na tabela cleaning_log e são mostradas quando o script corre.

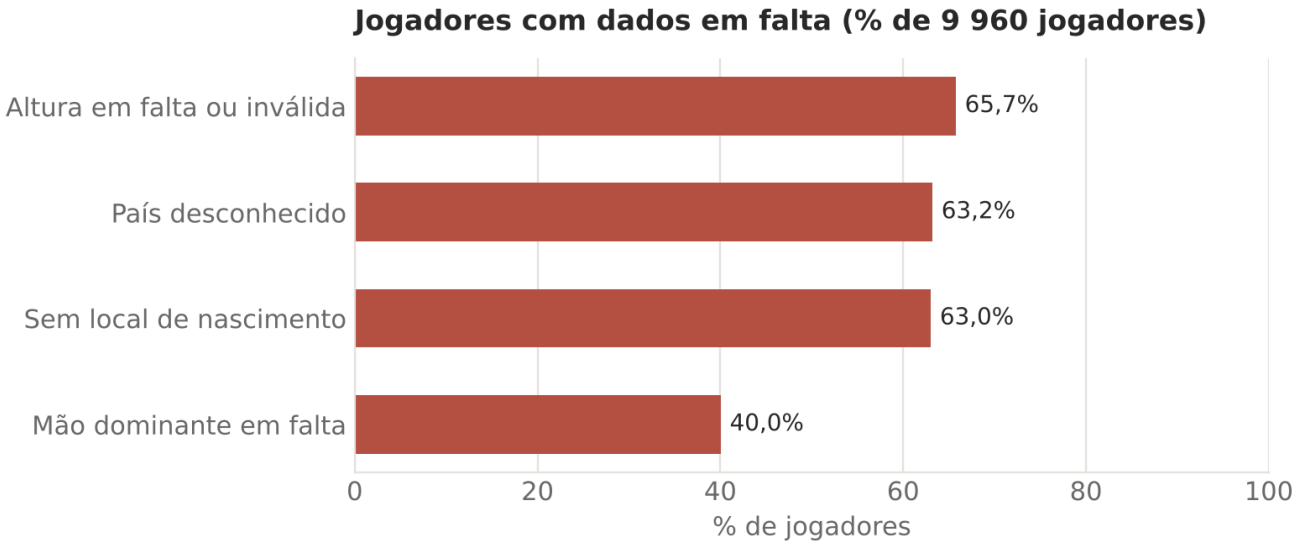
7. Linhas perdidas

Dos 1 308 835 documentos originais chegam à tabela game 1 286 812 jogos. Perdem-se 22 023 linhas (1,7%), quase todas byes, que não são jogos.

Etapa	Linhas	Perdidas
atpplayers.json (MongoDB, após mongoimport)	1 308 835	–
Após remover byes e registos sem W/L	1 289 575	19 260
Após remover duplicados exatos = CSV = atpdb.sql	1 286 829	2 746
Tabela game (MySQL)	1 286 812	17



No nível dos jogadores não se perde nenhum registo, mas faltam muitos dados. O país é conhecido para 3 667 dos 9 960 jogadores (36,8%). Dos que têm local de nascimento, 99,5% ficam com país; o problema são os 6 276 jogadores sem local de nascimento, que nenhuma lista de países resolve. Os jogadores sem país não entram na contagem de jogadores e rondas da consulta 1.



8. Decisões e pressupostos

Tema	Decisão	Justificação
Identificação do jogador	Código ATP do LinkPlayer	7 nomes são partilhados por jogadores diferentes
Jogadores por país	País de nascimento (Born)	É o único dado de nacionalidade no ficheiro
Torneios por país	Edições realizadas no país (Location)	O país do local é conhecido em 99,8% das edições; o país dos jogadores só em 37%
Rondas por país	Rondas que os jogadores do país avançaram = jogos ganhos, walkovers incluídos	Cada vitória faz avançar uma ronda
Lista de países	ISO 3166-1 e variantes incluídas no script (INSERTs), em vez de LOAD DATA do countries_net.csv	O script não pode depender de um ficheiro nem de local_infile
Cidades sem país	GeoNames quando a cidade não é ambígua; restantes à mão; ambíguas sem país	Evita atribuir um país errado (ex.: "San Juan" existe em Porto Rico, Filipinas e Argentina)
% de vitórias	Vitórias / jogos disputados; walkovers excluídos	Como no registo oficial da ATP, um walkover não é jogo disputado

Tema	Decisão	Justificação
Mínimo nas consultas 2 e 3	25 vitórias (na consulta 3, 25 vitórias em Grand Slams)	Sem mínimo, jogadores com 1 jogo ganho ficariam com 100%
Grand Slams	Australian Open (incl. Australian Open-1/-2 e Australian Championships), Roland Garros, Wimbledon e US Open; só o quadro principal	As rondas de qualificação e as "Preliminary Round" não são jogos de Grand Slam
Piso duro	Ground = "Hard"	Os outros pisos são Clay, Grass e Carpet
Níveis de torneio	Todos (ATP, Challenger, Futures, Taça Davis, qualificação)	O enunciado não restringe; explica nomes como Ti Chen na consulta 4
Jogos antes de 1973	Mantidos (264 edições)	São jogos reais dos mesmos jogadores
Países históricos	Czechoslovakia → República Checa; Yugoslavia e Serbia & Montenegro → Sérvia; Soviet Union → Rússia	País sucessor, por simplicidade

9. Resultados das consultas

As quatro consultas correm em menos de 2 segundos cada (MySQL 8.0, média de 3 execuções). Nas consultas 2 a 4 os jogos são agregados primeiro e o nome do jogador só é juntado no fim. Só com isto, a consulta 2 passou de 10 s para 0,7 s.

Consulta	Linhas devolvidas	Tempo
1. Por país	148	0,7 s
2. Top 10 % vitórias	10	0,7 s
3. Top 10 esquerdinos em Grand Slams	10	1,4 s
4. Top 5 vitórias em Hard	5	1,5 s

1) Por país (primeiras 10 linhas)

País	Jogadores	Torneios	Rondas
United States	467	2 441	46 439
Germany	221	1 081	30 282
France	219	1 085	37 130
Italy	189	1 354	29 612
Argentina	175	438	32 896
Australia	160	579	16 963
Spain	152	1 080	34 031
United Kingdom	134	710	13 397
Brazil	126	715	17 909
Russia	113	285	19 823

2) Top 10 por % de vitórias (mínimo 25 vitórias)

Jogador	Vitórias	Jogos	% vitórias
Rafael Nadal	1 119	1 343	83,32
Novak Djokovic	1 045	1 262	82,81
Bjorn Borg	654	794	82,37
Jimmy Connors	1 275	1 558	81,84
Roger Federer	1 267	1 549	81,79
John McEnroe	883	1 081	81,68
Ivan Lendl	1 071	1 314	81,51
Pete Sampras	763	988	77,23
Boris Becker	713	928	76,83
Andre Agassi	885	1 163	76,10

3) Top 10 esquerdinos em Grand Slams (mínimo 25 vitórias)

Jogador	Vitórias GS	Jogos GS	% vitórias
Rafael Nadal	298	339	87,91
Jimmy Connors	233	282	82,62
John McEnroe	167	205	81,46
Guillermo Vilas	138	183	75,41
Goran Ivanisevic	110	160	68,75
Thomas Muster	77	115	66,96
Andres Gomez	61	92	66,30
Marcelo Rios	51	77	66,23
Henri Leconte	78	122	63,93
Denis Shapovalov	29	46	63,04

4) Top 5 vitórias em piso duro

Jogador	Vitórias em Hard
Roger Federer	790
Novak Djokovic	648
Andre Agassi	606
Ti Chen	606
Yen-Hsun Lu	562

Ti Chen e Yen-Hsun Lu aparecem porque os dados incluem Challengers e Futures. Em caso de empate (Agassi e Ti Chen, 606), a ordem é alfabética.

10. Como testar

Os ficheiros correm por esta ordem e nenhum depende de ficheiros externos além do atpplayers.json.

1. MongoDB com a coleção atpplayers na bd atp (mongoimport do atpplayers.json): `mongosh "mongodb://localhost:27017/atp" --file atpscript.json` (ou `load("atpscript.json")` dentro do mongosh).
2. MySQL com a bd atp vazia: `mysql -u <utilizador> -p < atpdb.sql` (cerca de 30 s).
3. `mysql -u <utilizador> -p < atpscript.sql` (cerca de 2 min). Mostra as contagens da limpeza e o resultado das 4 consultas.

O atpscript.sql foi testado de raiz (bd vazia → dump → script) e também a correr duas vezes seguidas, sem erros.